

Analisis Dampak Energi Ramah Lingkungan pada Bangunan terhadap Kualitas Udara dengan Metode *Stacking XGBoost* dan *Random Forest* Melalui *Bayesian Optimization*

1st Evan Santosa
Computer Science
Universitas Bina Nusantara
Jakarta, Indonesia
evan.santosa001@binus.ac.id

2nd Elena Nathanielle
Data Science
Universitas Bina Nusantara
Jakarta, Indonesia
elena.angkawi@binus.ac.id

Abstract—Penggunaan energi ramah lingkungan merupakan suatu solusi untuk mengurangi dampak dari polusi udara dan meningkatkan kualitas udara bersih. Analisis dampak energi ramah lingkungan terhadap kualitas udara menjadi penting untuk memahami kontribusinya dalam mendukung kebijakan energi berkelanjutan. Kajian literatur menunjukkan bahwa metode *machine learning*, seperti model *ensemble* dan teknik regresi, memiliki kemampuan untuk menganalisis hubungan kompleks dalam data lingkungan. Selain itu, optimasi *Bayesian* diketahui efektif dalam meningkatkan performa model melalui tuning hiperparameter secara sistematis. Dalam penelitian ini, data lingkungan dan atribut bangunan diproses menggunakan kerangka kerja CRISP-DM (*Cross-Industry Standard Process for Data Mining*). Berbagai model *machine learning*, termasuk *Stacking* yang mengintegrasikan *XGBoost* dan *Random Forest*, serta *Lasso Regression*, diterapkan dan dioptimalkan menggunakan pendekatan *Bayesian*. Meta model *Lasso Regression* menunjukkan performa terbaik dengan nilai R^2 sebesar 0,9975. Hasil penelitian juga mengindikasikan bahwa adanya korelasi negatif kuat antara persentase energi terbarukan dan indeks kualitas udara. Penemuan ini mendukung pentingnya adopsi energi ramah lingkungan dan teknologi efisiensi energi untuk mendukung upaya perbaikan kualitas lingkungan secara berkelanjutan.

Keywords—energi ramah lingkungan, kualitas udara, *machine learning*, algoritma *random forest*, algoritma *xgboost*, *stacking*

I. PENDAHULUAN

A. Latar Belakang

Energi terbarukan telah menjadi pilar penting dalam upaya global untuk mengurangi dampak lingkungan dari penggunaan bahan bakar fosil. Sumber energi seperti matahari, angin, air, dan biomassa menawarkan alternatif yang bersih dan berkelanjutan untuk memenuhi kebutuhan energi yang terus meningkat. Panwar et al. (2011) menyebutkan bahwa energi terbarukan tidak hanya mengurangi emisi karbon dioksida tetapi juga membantu negara-negara mencapai kemandirian energi. Selain itu, implementasi energi terbarukan dapat membuka peluang ekonomi melalui penciptaan lapangan kerja di sektor-sektor hijau. Namun, keberhasilan transisi ke energi terbarukan membutuhkan analisis yang cermat antara teknologi, kebijakan, dan pemahaman dampak terhadap lingkungan sekitar, termasuk pada kualitas udara.

Kualitas udara yang buruk telah menjadi ancaman serius terhadap kesehatan manusia dan ekosistem. Organisasi Kesehatan Dunia (*World Health Organization*) memperkirakan bahwa lebih dari tujuh juta kematian prematur per tahun disebabkan oleh paparan polusi udara [1]. Faktor-faktor seperti emisi kendaraan, pembangkit listrik berbasis batu bara, dan aktivitas industri lainnya secara signifikan memperburuk tingkat polusi udara. Dampak dari kualitas udara yang buruk meliputi gangguan pernapasan, penyakit kardiovaskular, dan kerusakan ekosistem. Menurut Brauer (2016), upaya untuk memperbaiki kualitas udara harus melibatkan pendekatan yang lebih sistematis, termasuk menggali hubungan antara sumber energi bersih dan perubahan kualitas udara untuk menemukan solusi yang berkelanjutan.

Dalam hal ini, *machine learning* telah menunjukkan potensi besar dalam memecahkan masalah-masalah kompleks, termasuk yang berkaitan dengan lingkungan. Teknologi ini memungkinkan analisis data dalam jumlah besar untuk mengidentifikasi pola yang tidak terlihat oleh pendekatan konvensional [2]. Dalam konteks kualitas udara, *machine learning* dapat digunakan untuk memodelkan dampak dari berbagai sumber energi terhadap tingkat polusi di atmosfer. Zhang (2020) menemukan bahwa algoritma prediktif seperti *Random Forest* dan *Neural Networks* dapat membantu memetakan hubungan antara penggunaan energi terbarukan dan parameter kualitas udara. Penggunaan *machine learning* tidak hanya mempercepat proses analisis, tetapi juga membantu para pihak pemerintahan dalam mengambil keputusan berbasis data (*data driven*) [3].

B. Rumusan Masalah

- Bagaimana kontribusi energi terbarukan dalam mengurangi dampak negatif terhadap kualitas udara?
- Bagaimana *machine learning* dapat digunakan untuk memodelkan hubungan antara energi terbarukan dan kualitas udara?

C. Tujuan dan Manfaat

a) Tujuan

Penelitian ini dilakukan dengan tujuan berikut:

- Mengidentifikasi kontribusi energi terbarukan dalam memperbaiki kualitas udara.

- Memodelkan hubungan antara penggunaan energi ramah lingkungan dan parameter kualitas udara menggunakan metode *machine learning*.
- Mengungkap faktor-faktor utama yang memengaruhi efektivitas energi terbarukan dalam mengurangi polusi udara.

b) Manfaat

Manfaat yang diharapkan dari penelitian ini:

- Memberikan wawasan ilmiah mengenai dampak energi terbarukan terhadap lingkungan, khususnya kualitas udara.
- Menyediakan pendekatan berbasis data memprediksi perubahan kualitas udara sebagai akibat dari transisi ke energi terbarukan.
- Menjadi dasar pengambilan keputusan bagi pembuat kebijakan dalam merancang strategi energi berkelanjutan yang efektif.
- Membuka peluang untuk integrasi teknologi *machine learning* dalam solusi lingkungan yang lebih luas.
- Berkontribusi pada pengembangan literatur ilmiah tentang peran energi terbarukan dan *machine learning* dalam mendukung keberlanjutan.

II. PEMBAHASAN

A. Landasan Teori

1) Sumber Daya Energi Terbarukan

Sumber daya energi terbarukan adalah jenis sumber energi yang berasal dari proses alamiah yang dapat diperbarui dalam jangka waktu yang relatif singkat. Energi ini mencakup energi surya, angin, hidro, biomassa, dan panas bumi. Sebagai alternatif energi fosil yang tidak dapat diperbaharui, sumber daya energi terbarukan menawarkan solusi untuk mengurangi dampak lingkungan dan ketergantungan pada sumber daya yang terbatas (Twidell & Weir, 2015).

Pemanfaatan energi terbarukan memiliki banyak manfaat, termasuk pengurangan emisi gas rumah kaca dan penghematan biaya operasional dalam jangka panjang. Pengembangan teknologi seperti panel surya dan turbin angin telah meningkatkan efisiensi dan aksesibilitas sumber daya energi ini (Jake Guitenberg., 2011). Energi terbarukan juga berperan dalam mendukung kemandirian energi nasional dan pembangunan berkelanjutan.

Meski demikian, terdapat tantangan seperti kebutuhan modal awal yang tinggi dan keterbatasan dalam penyimpanan energi [4]. Strategi seperti integrasi teknologi baterai dan kebijakan dukungan pemerintah dapat membantu mengatasi tantangan ini. Inisiatif global untuk mempercepat praktek energi terbarukan semakin meningkat, termasuk melalui transfer teknologi dalam skala internasional (IEA, 2020).

2) Kualitas Udara

Kualitas udara merujuk pada kondisi udara di lingkungan tertentu, yang ditentukan oleh konsentrasi polutan seperti partikel halus ($PM_{2.5}$ dan PM_{10}), nitrogen dioksida (NO_2), dan sulfur dioksida (SO_2). Polusi udara

berdampak buruk pada kesehatan manusia, termasuk meningkatkan risiko penyakit pernapasan dan kardiovaskular (WHO, 2021).

Faktor utama yang memengaruhi kualitas udara meliputi aktivitas manusia, seperti emisi kendaraan bermotor, pembakaran bahan bakar fosil, dan kegiatan industri [5]. Selain itu, kondisi geografis dan meteorologis juga memainkan peran penting. Pemantauan kualitas udara dilakukan menggunakan stasiun pengukuran atau satelit untuk menyediakan data akurat bagi pengambil kebijakan.

Upaya untuk meningkatkan kualitas udara melibatkan penerapan teknologi bersih, seperti kendaraan listrik dan sistem filtrasi industri, serta kebijakan pengendalian emisi yang ketat [6]. Edukasi masyarakat tentang pentingnya kualitas udara yang baik juga menjadi langkah penting dalam mendukung inisiatif ini (Anderson, 2012).

3) Machine Learning

Machine Learning (ML) adalah cabang dari kecerdasan buatan (*Artificial Intelligence*) yang berfokus pada pengembangan algoritma dan model komputer yang mampu belajar dan membuat prediksi atau keputusan tanpa pemrograman eksplisit. Pendekatan ini bertujuan untuk mengeksplorasi data yang tersedia untuk mengidentifikasi pola, struktur, atau hubungan dalam dataset [7]. Secara mendasar, *machine learning* memanfaatkan statistik, matematika, dan teori probabilitas untuk mendukung proses pembelajaran dan prediksi. Aplikasi teknologi ini mencakup berbagai bidang, seperti pengenalan suara, pengolahan bahasa alami, analisis data medis, dan sistem rekomendasi.

Proses *machine learning* secara umum dibagi menjadi tiga kategori utama: *supervised learning*, *unsupervised learning*, dan *reinforcement learning* [8]. *Supervised learning* melibatkan data berlabel, di mana model dilatih untuk memetakan input terhadap output berdasarkan data historis, seperti dalam klasifikasi dan regresi. *Unsupervised learning*, di sisi lain, bekerja dengan data tanpa label dan bertujuan untuk menemukan struktur tersembunyi, seperti dalam klusterisasi atau pengurangan dimensi. *Reinforcement learning* berfokus pada pelatihan agen untuk mengambil tindakan dalam lingkungan tertentu agar dapat memaksimalkan reward, yang sering diterapkan dalam robotika dan permainan komputer.

Dalam implementasinya, keberhasilan *machine learning* bergantung pada kualitas data, pemilihan model, dan kemampuan sistem untuk menangani tantangan seperti *overfitting* atau *underfitting*. Sebagai contoh, *deep learning* adalah subbidang *machine learning* yang menggunakan arsitektur jaringan saraf tiruan (*neural networks*) untuk memproses data kompleks dengan efisiensi tinggi. Namun, keberhasilan model juga ditentukan oleh ketersediaan data yang cukup, performa algoritma, dan optimalisasi *hyperparameter*. Dalam praktiknya, penggunaan *machine learning* perlu mempertimbangkan tidak hanya akurasi, tetapi juga interpretabilitas model, dampak etis, dan bias yang mungkin terkandung dalam data.

4) Algoritma XGBoost

Extreme Gradient Boosting (XGBoost) adalah algoritma *machine learning* berbasis *ensemble* yang dikembangkan untuk meningkatkan kecepatan dan efisiensi *gradient boosting*. *XGBoost* dikenal karena kemampuannya menangani data dengan dimensi tinggi dan fitur sparsitas dengan baik [9]. Algoritma ini banyak digunakan dalam praktek sehari-hari karena akurasi dan performanya yang unggul (Chen & Guestrin, 2016).

XGBoost menggunakan strategi *boosting*, di mana model lemah dibangun secara iteratif untuk memperbaiki kesalahan dari model sebelumnya. Proses ini dilengkapi dengan regularisasi untuk mencegah *overfitting*, menjadikannya pilihan yang andal untuk berbagai jenis data (Friedman, 2001). Selain itu, *XGBoost* mendukung paralelisasi, sehingga meningkatkan efisiensi komputasi. Rumus matematis untuk model *XGBoost* adalah:

$$\hat{y}_i = \sum_{k=1}^K f_k(x_i), f_k \in F \quad (1)$$

XGboost mengoptimalkan fungsi objektif berikut:

$$L(\theta) = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k) \quad (2)$$

Rumus utama dari *XGBoost* adalah $\sum_{k=1}^K f_k(x_i)$, di mana $\hat{y}_i$ adalah prediksi untuk data ke- i , K merupakan jumlah pohon Keputusan dalam model, dan $f_k(x_i)$ adalah prediksi dari pohon ke- k untuk data x_i . Fungsi $f_k(x_i)$ berasal dari ruang pohon keputusan F , yang mencakup semua pohon dengan kedalaman tertentu. *XGBoost* mengoptimalkan fungsi objektif $L(\theta) = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k)$, di mana $l(y_i, \hat{y}_i)$ adalah *loss function* dan $\Omega(f_k)$ adalah istilah regularisasi yang membantu untuk mencegah terjadinya *overfitting*, dengan ekspresi $\Omega(f_k) = \gamma T_k + \frac{1}{2} \lambda \|w\|^2$, yang menggabungkan jumlah node pada pohon (T_k) dan bobot di setiap node (w), dengan γ sebagai control jumlah node dan λ sebagai parameter regularisasi L2 [10].

Penggunaan *XGBoost* sangat luas, mulai dari prediksi harga hingga pengklasifikasian gambar. Namun, *tuning hyperparameter* menjadi salah satu tantangan yang membutuhkan waktu dan keahlian. Implementasi yang hati-hati dapat memberikan hasil yang sangat baik bahkan pada dataset yang kompleks.

5) Algoritma Regresi Random Forest

Random Forest adalah metode *ensemble learning* berbasis pohon keputusan yang digunakan untuk klasifikasi dan regresi. Dalam regresi, algoritma ini membangun banyak pohon keputusan, kemudian menggabungkan prediksi mereka dengan menghitung rata-rata untuk menghasilkan nilai output (Breiman, 2001).

Keunggulan algoritma *Random Forest* terletak pada kemampuannya menangani dataset yang besar dan kompleks tanpa terlalu rentan terhadap *overfitting*. Selain itu, algoritma ini juga memberikan fitur penting seperti estimasi *importance* variabel, yang membantu dalam interpretasi model (Cutler, 2007).

Namun, salah satu kelemahan dari *Random Forest* adalah waktu komputasi yang lebih lama dibandingkan metode linear, terutama untuk dataset besar. Untuk mengatasi ini, implementasi paralel dapat diterapkan

untuk mempercepat proses pembelajaran [11]. *Random Forest* tetap menjadi metode yang populer karena keandalannya dalam berbagai aplikasi.

Berikut adalah rumus utama dari *Random Forest*:

$$y_i = \frac{1}{B} \sum_{b=1}^B f_b(x_i) \quad (3)$$

Di rumus ini y_i adalah prediksi untuk data ke- i , B adalah jumlah pohon dalam ensemble, dan $f_b(x_i)$ adalah prediksi yang dihasilkan oleh pohon ke- b untuk data x_i . Model ini menggunakan pendekatan *bootstrap aggregating* (bagging), yang melibatkan pelatihan setiap pohon keputusan menggunakan subset data yang dipilih secara acak (dengan pengembalian). Selain itu, subset fitur juga dipilih secara acak untuk setiap split pada pohon. Dengan cara ini, *Random Forest* mengurangi *overfitting* dan meningkatkan robusta prediksi karena setiap pohon dilatih secara independen tanpa saling memengaruhi, dan hasil akhir diperoleh dengan mengambil rata-rata prediksi dari semua pohon dalam ensemble.

6) Metode Stacking

Metode *stacking* adalah teknik *ensemble learning* yang menggabungkan prediksi dari beberapa model *machine learning* untuk meningkatkan performa prediksi secara keseluruhan. Teknik ini bekerja dengan menggabungkan model tingkat pertama (*base learners*) menggunakan model tingkat kedua (*meta-learner*) untuk menghasilkan prediksi akhir (Wolpert, 1992).

Keunggulan utama *stacking* adalah kemampuannya memanfaatkan kekuatan dari model-model yang berbeda, seperti kombinasi antara algoritma linier dan non-linier. Misalnya, model regresi logistik dapat digunakan sebagai *meta-learner* untuk menggabungkan prediksi dari *Random Forest* dan SVM.

Namun, penerapan *stacking* memerlukan pengelolaan yang hati-hati terhadap data pelatihan dan pengujian, seperti menggunakan *cross-validation* untuk mencegah *data leakage*. Ketika diterapkan dengan tepat, *stacking* dapat menghasilkan model yang lebih akurat dibandingkan metode *ensemble* lainnya seperti *bagging* atau *boosting*.

7) Bayesian Optimization

Bayesian Optimization adalah metode pencarian optimasi yang bertujuan memaksimalkan atau meminimalkan fungsi obyektif yang mahal untuk dievaluasi [12]. Metode ini menggunakan model probabilistik, seperti *Gaussian Process*, untuk mengaproksimasi fungsi obyektif dan memandu proses pencarian (Mockus, 1978).

Proses optimasi dilakukan dengan memaksimalkan fungsi akuisisi, yang menentukan titik mana yang harus dievaluasi berikutnya. Metode ini sangat efektif untuk *tuning hyperparameter* dalam model pembelajaran mesin karena mampu mengurangi jumlah eksperimen yang diperlukan (Snoek, 2012).

Bayesian Optimization biasanya menggunakan *Gaussian Process* (GP) sebagai *surrogate model*. Dalam *Gaussian Process*, prediksi fungsi obyektif $f(x)$ dimodelkan sebagai distribusi normal:

$$f(x) \sim N(\mu(x), \sigma^2(x)) \quad (4)$$

$f(x)$ sebagai nilai *mean* pada titik x , dan $\sigma^2(x)$ sebagai varians dari prediksi di x .

Keunggulan *Bayesian Optimization* adalah kemampuannya menemukan solusi optimal dalam ruang pencarian yang besar dengan evaluasi yang relatif sedikit [13]. Namun, pendekatan ini mungkin tidak efisien untuk masalah dengan dimensi yang sangat tinggi atau fungsi obyektif yang sangat kompleks.

8) Cross Validation

Cross-validation adalah teknik statistik yang digunakan untuk mengevaluasi performa model pembelajaran mesin dengan cara membagi data menjadi beberapa subset. Subset ini digunakan secara bergantian sebagai data pelatihan dan data pengujian untuk mendapatkan estimasi akurasi model yang lebih akurat dan generalisasi yang lebih baik (Stone, 1974).

Metode *cross-validation* yang umum digunakan meliputi *k-fold cross-validation*, *leave-one-out*, dan *stratified k-fold* [14]. *K-fold* adalah metode yang paling populer, di mana dataset dibagi menjadi k bagian, dan setiap bagian bergiliran menjadi data pengujian, sementara sisanya digunakan untuk pelatihan. *Stratified k-fold* digunakan jika distribusi kelas tidak seimbang, untuk memastikan pembagian yang merata.

Keuntungan utama *cross-validation* adalah kemampuannya memberikan gambaran yang lebih *robust* tentang kinerja model, terutama pada dataset dengan ukuran kecil. Namun, teknik ini bisa menjadi sangat memakan waktu jika digunakan dengan model yang kompleks, sehingga memerlukan alokasi sumber daya yang memadai.

B. Metode penelitian

Metode penelitian akan menggunakan *framework Cross-Industry Standard Process for Data Mining (CRISP-DM)*. Berikut adalah diagram untuk proses penelitian:




Fig. 1. Diagram CRISP-DM

1) Business Understanding

Peningkatan polusi udara akibat aktivitas manusia, termasuk konsumsi energi yang tidak ramah lingkungan, menjadi tantangan besar di berbagai sektor, terutama di lingkungan perkotaan. Bangunan sebagai salah satu pengguna utama energi memberikan kontribusi signifikan terhadap emisi gas rumah kaca, yang memengaruhi kualitas udara secara langsung. Oleh karena itu, penting untuk memahami bagaimana energi ramah lingkungan dapat menjadi alternatif untuk membantu mengurangi dampak negatif ini [15]. Dalam konteks ini, analisis berbasis *machine learning* memberikan potensi besar

untuk mengungkap hubungan kompleks antara penggunaan energi ramah lingkungan pada bangunan dengan peningkatan kualitas udara. Informasi ini dapat digunakan untuk mendukung pengambilan keputusan strategis dalam perencanaan energi dan desain bangunan yang lebih berkelanjutan.

Selain itu, dengan memanfaatkan *machine learning*, penelitian ini bertujuan untuk membangun model prediksi yang tidak hanya membantu mengukur pengaruh energi ramah lingkungan terhadap kualitas udara, tetapi juga memberikan wawasan yang dapat digunakan oleh pemangku kebijakan dan pelaku industri [16]. Hasil analisis diharapkan dapat memberikan dasar ilmiah yang kuat untuk mendorong adopsi teknologi dan kebijakan energi bersih pada bangunan. Dengan demikian, implementasi penelitian ini dapat mendukung tujuan keberlanjutan dalam pengelolaan lingkungan, sekaligus menciptakan lingkungan perkotaan yang lebih sehat.

Judul Penelitian	Pencipta
<i>Exploring the Role of Renewable Energy in Reducing Air Pollution: A Case Study of Urban Building</i>	J. Smith & M. Green
<i>The Impact of Green Energy Transitions on Air Quality: Evidence from Building Emission Models</i>	A. Johnson, R. Lee, & K. Brown

Fig. 2. Tabel Penelitian Terdahulu

2) Data Understanding

Penelitian ini menggunakan dua dataset utama: *environmental dataset* (9859 baris) dan *building dataset* (9483 baris), yang dirancang untuk menggambarkan hubungan antara kondisi lingkungan dan karakteristik bangunan terhadap kualitas udara. *Environmental dataset* mencakup berbagai atribut yang menggambarkan kondisi kualitas udara, konsumsi energi, dan faktor lingkungan. Beberapa variabel utama dalam dataset ini mencakup lokasi geografis sensor (*SensorLocation*), konsentrasi berbagai polutan udara seperti $PM_{2.5}$, PM_{10} , NO_2 , CO , dan SO_2 , tingkat kelembapan (*Humidity_%*), suhu udara (*AirTemperature_C*), luas vegetasi di area urban (*UrbanVegetationArea_m2*), penggunaan teknologi hemat energi (*EnergySavingTechnology*), dan persentase energi terbarukan yang digunakan (*RenewableEnergyPercentage_%*). Selain itu, dataset ini juga mencakup indeks kualitas udara (*AQI_Index*) serta data terkait konsumsi energi tahunan (*AnnualEnergyConsumption_kWh*) dan persentase penghematan energi tahunan (*AnnualEnergySavings_%*). Dengan berbagai informasi tersebut, dataset ini memberikan gambaran detail tentang kondisi lingkungan dan dampaknya terhadap kualitas udara.

Sementara itu, *building dataset* fokus pada karakteristik bangunan dan penggunaannya dalam mendukung penghematan energi dan penggunaan energi terbarukan. Atribut dalam dataset ini mencakup jenis bangunan (*BuildingType*), tahun bangunan dibangun (*YearBuilt*), konsumsi listrik bulanan (*MonthlyElectricityConsumption_kWh*), jam puncak penggunaan listrik (*PeakUsageTime_Hour*), dan jenis energi terbarukan yang digunakan (*RenewableType*). Variabel seperti efisiensi energi (*EnergyEfficiency_kWh_per_m2*), kapasitas energi

terbarukan yang terpasang (*RenewableCapacity_kWh*), serta durasi intensitas sinar matahari (*WeatherData_SolarIntensity_Hours*) dan kecepatan angin (*WeatherData_WindSpeed_km_h*) memberikan konteks tambahan terkait hubungan antara desain bangunan dan efisiensi energi. Dataset ini juga dilengkapi dengan data sumber energi utama yang digunakan (*EnergySource*), sehingga mendukung analisis yang lebih dalam terhadap peran bangunan dalam pengurangan emisi dan peningkatan kualitas udara. Kombinasi kedua dataset ini memberikan kerangka kerja yang komprehensif untuk membangun model pembelajaran mesin yang mampu mengidentifikasi pengaruh energi ramah lingkungan terhadap kualitas udara.

3) Data Preparation

Tahap *data preparation* dilakukan untuk memastikan terhadap bahwa dataset siap digunakan dalam proses analisis dan pemodelan. Pertama, pemeriksaan nilai *null* dan duplikat dilakukan sebagai langkah awal. Nilai *null* diidentifikasi dan ditangani menggunakan metode imputasi, seperti *mean* atau *median* untuk fitur numerik serta modus untuk fitur kategorik. Data duplikat dihapus untuk menghindari bias yang dapat memengaruhi kinerja model *machine learning*.

Setelah data bersih, tahap berikutnya adalah *scaling* untuk menyelaraskan skala fitur numerik, yang diperlukan terutama ketika algoritma pembelajaran mesin sensitif terhadap perbedaan skala. Metode seperti *Min-Max Scaling* atau *Standardization* diterapkan untuk memastikan distribusi data numerik sesuai. Untuk fitur kategorik, dilakukan proses encoding agar dapat diinterpretasikan oleh algoritma *machine learning*. Teknik yang digunakan termasuk *One-Hot Encoding* untuk kategori tanpa urutan hierarki dan *Label Encoding* jika kategori memiliki hubungan ordinal. Proses ini menghasilkan dataset yang lebih terstruktur dan kompatibel untuk diterapkan pada berbagai model *machine learning*.

C. Hasil dan Pembahasan

Penggunaan energi terbarukan memiliki pengaruh terhadap kualitas udara. Hal ini dapat dilihat dari *feature importance* dari masing-masing fitur dengan indeks kualitas udara (AQI). Persentase energi terbarukan memiliki *feature importance* tertinggi kedua setelah polutan-polutan udara dan penghematan energi.

Selain itu, korelasi antara penggunaan energi terbarukan dengan indeks kualitas memiliki nilai yang negatif. Hal ini menunjukkan semakin besar penggunaan energi terbarukan, semakin kecil nilai AQI. Oleh karena itu, semakin besar penggunaan energi terbarukan, kualitas udara dapat menjadi lebih baik. Begitu pula dengan sebaliknya.

Adapun kadar polutan yang paling terpengaruh dengan adanya energi terbarukan yaitu $PM_{2.5}$. Hal ini disebabkan sumber energi yang digunakan sering kali menghasilkan emisi yang menjadi penyebab utama terbentuknya partikel tersebut. Semakin besar penggunaan energi dari sumber yang tidak bersih atau tidak terbarukan, semakin besar polutan yang dihasilkan. Oleh sebab itu, diperlukan peningkatan efisiensi energi agar kadar-kadar polutan dapat berkurang dan kualitas udara dapat menjadi lebih baik.

Untuk meningkatkan efisiensi energi, terdapat beberapa faktor yang dapat dipertimbangkan. Yang pertama, teknologi penghematan energi.




Fig. 3. Bar Chart Pengaruh Teknologi Terhadap Persentase Penghematan Energi

Grafik di atas menunjukkan pengaruh teknologi penghematan energi terhadap rata-rata persentase penghematan energi tahunan. Berdasarkan grafik tersebut, teknologi *smart thermostats* menjadi teknologi dengan tingkat efisiensi paling tinggi. Hal ini disebabkan *smart thermostats* dapat mempelajari pola kebiasaan pengguna dan optimalisasi suhu sehingga dapat mengatur penggunaan energi dengan lebih efisien.

Yang kedua, tipe energi terbarukan. Energi terbarukan biomassa (*biomass*) dapat menghasilkan rata-rata efisiensi energi tertinggi. Hal ini disebabkan biomassa berasal dari bahan organik yang dapat diperbaharui, seperti tanaman, limbah pertanian, limbah rumah tangga, atau limbah industri. Selain itu, energi biomassa juga memiliki proses pembakaran yang lebih ramah lingkungan. Berikut merupakan grafik pengaruh tipe energi terbarukan terhadap rata-rata efisiensi energi yang dicapai.




Fig. 4. Bar Chart Efisiensi Berdasarkan Tipe Energi

Sumber energi utama yang digunakan dalam bangunan juga mempengaruhi efisiensi energi.




Fig. 5. Bar Chart Efisiensi Berdasarkan Sumber Energi

Berdasarkan grafik pengaruh sumber energi utama bangunan terhadap rata-rata efisiensi energi yang dicapai, energi biomassa kembali mencapai efisiensi energi yang tertinggi, kemudian diikuti oleh listrik, energi campuran, gas alami, batu bara, minyak, dan nuklir.

Menariknya, saat ini bangunan keagamaan telah mencapai efisiensi energi tertinggi jika dibandingkan dengan tipe bangunan lainnya.




Fig. 6. Bar Chart Efisiensi Berdasarkan Tipe Bangunan

Hal ini disebabkan bangunan keagamaan memiliki jam operasional yang terbatas sehingga energi yang dibutuhkan juga sedikit. Tidak hanya itu, bangunan keagamaan juga menggunakan desain arsitektur yang efisien dengan menggunakan banyak ventilasi alami sehingga dapat meminimalisir penggunaan energi.

Selain itu, bangunan keagamaan juga menggunakan energi terbarukan yang cukup besar. Berdasarkan hasil penelitian, rata-rata bangunan keagamaan telah menggunakan 61,12% energi terbarukan. Hal ini berbanding terbalik dengan bangunan kesehatan yang baru memiliki rata-rata 59,01%. Oleh sebab itu, persentase penggunaan energi terbarukan juga berpengaruh terhadap efisiensi energi yang dicapai.

Energi terbarukan dapat mengurangi dampak negatif kualitas udara, apalagi jika menggunakan teknologi dan sumber energi yang tepat. Hal ini sesuai dengan teori yang menyampaikan teknologi bersih dapat meningkatkan kualitas udara.

Agar dapat memprediksi kualitas udara kedepannya, diperlukan penerapan *machine learning*. Adapun algoritma yang digunakan yaitu *Random Forest*, *XGBoost*, *Stacking (Random Forest x XGBoost) Using Linear Regression as*

Meta Model, dan *Stacking (Random Forest x XGBoost Using Lasso Regression as Meta Model)*.

Algoritma-algoritma tersebut akan digunakan untuk memprediksi kualitas udara berdasarkan faktor-faktor seperti penggunaan energi. Adapun hasil evaluasi performa algoritma *machine learning* yang digunakan dapat dilihat pada tabel berikut.

Jenis Algoritma	MSE	R ² Score
Random Forest	135.14	0.9098
XGBoost	4.04	0.9973
Stacking (Random Forest x XGBoost) Using Linear Regression as Meta Model	3.77	0.9975
Stacking (Random Forest x XGBoost) Using Lasso Regression as Meta Model	3.76	0.9975

Fig. 7. Tabel Evaluasi

Berdasarkan tabel di atas, evaluasi terhadap performa berbagai algoritma dalam menganalisis dampak energi ramah lingkungan kualitas udara menunjukkan bahwa algoritma *XGBoost* secara individu memberikan kinerja yang jauh lebih baik dibandingkan *Random Forest*, dengan nilai MSE (*Mean Squared Error*) sebesar 4,04 dan R² Score sebesar 0,9973 dibandingkan nilai MSE sebesar 135,14 dan R² Score sebesar 0,9098 untuk *Random Forest*. Model *stacking*, yang mengombinasikan *Random Forest* dan *XGBoost* dengan menggunakan regresi linear atau regresi lasso sebagai *meta-model*, menunjukkan peningkatan performa lebih lanjut. Model *stacking* dengan meta-model regresi linear menghasilkan nilai MSE sebesar 3,77 dan R² Score sebesar 0,9975, sedangkan model *stacking* dengan meta-model regresi lasso menghasilkan nilai MSE sebesar 3,76 dan R² Score sebesar 0,9975, menjadikannya sebagai model dengan kinerja terbaik. Oleh karena itu, model *stacking* dengan regresi lasso sebagai *meta-model* dianggap paling optimal dalam penelitian ini.

III. PENUTUP

A. Kesimpulan

Berdasarkan penelitian yang sudah dilakukan, penggunaan energi terbarukan memiliki dampak signifikan terhadap peningkatan kualitas udara. Hal ini ditunjukkan melalui *feature importance*, di mana persentase energi terbarukan memiliki kontribusi terbesar terhadap indeks kualitas udara (AQI) setelah faktor polutan. Korelasi negatif antara persentase energi terbarukan dan indeks kualitas udara mengindikasikan bahwa peningkatan penggunaan energi terbarukan dapat menurunkan nilai AQI, yang berarti kualitas udara menjadi lebih baik. Selain itu, pemanfaatan teknologi penghematan energi, seperti *smart thermostats*, serta penggunaan energi terbarukan biomassa, terbukti memiliki pengaruh positif dalam meningkatkan efisiensi energi dan mendukung upaya perbaikan kualitas udara.

Dalam hal pemodelan prediksi kualitas udara, algoritma *stacking* (kombinasi *Random Forest* dan *XGBoost*) dengan meta-model regresi lasso menghasilkan performa terbaik dengan nilai MSE sebesar 3,76 dan R² Score sebesar 0,9975. Model ini tidak hanya memberikan akurasi tinggi, tetapi juga membuktikan efektivitas pendekatan *ensemble* dalam menangani kompleksitas data terkait energi dan kualitas udara.

B. Rekomendasi

- Mendorong investasi dalam sektor energi terbarukan. Kerjasama antara sektor publik dan swasta dalam pembangunan infrastruktur energi bersih, seperti instalasi pembangkit listrik tenaga surya, angin, atau biomassa, juga dapat membantu dalam mengatasi isu lingkungan global.
- Peneliti selanjutnya dapat fokus pada analisis data jangka panjang untuk mengidentifikasi dampak penggunaan energi ramah lingkungan terhadap perubahan kualitas udara secara bertahap.
- Mengembangkan model prediksi real-time dengan bantuan data sensor IoT (*Internet of Things*) sehingga dapat digunakan lebih cepat dan efisien dalam pengambilan keputusan kebijakan energi dan lingkungan.

REFERENCES

- [1] World Health Organization, "Ambient air pollution: Health impacts," WHO, 2023. [Online]. Available: [https://www.who.int/news-room/fact-sheets/detail/ambient-\(outdoor\)-air-quality-and-health](https://www.who.int/news-room/fact-sheets/detail/ambient-(outdoor)-air-quality-and-health). [Accessed: Dec. 27, 2024].
- [2] J. Dean and S. Ghemawat, "MapReduce: Simplified Data Processing on Large Clusters," *Commun. ACM*, vol. 51, no. 1, pp. 107–113, 2008.
- [3] A. Culotta, "Reducing lag time and error in decision making with predictive modeling," *Int. J. Forecasting*, vol. 35, no. 4, pp. 1095–1105, Oct. 2019.
- [4] R. Luthander, J. Widén, D. Nilsson, and J. Palm, "Photovoltaic self-consumption in buildings: A review," *Appl. Energy*, vol. 142, pp. 80–94, Mar. 2015.
- [5] S. K. Guttikunda and G. Carmichael, "The contribution of vehicular emissions to ambient air pollution," *Atmospheric Environ.*, vol. 43, no. 1, pp. 128–139, 2009.
- [6] A. Markandya and P. Wilkinson, "Electric vehicles and their impact on reducing urban air pollution," *Lancet*, vol. 391, no. 10126, pp. 1970–1971, 2018.
- [7] R. Kohavi and F. Provost, "Glossary of terms in data mining and knowledge discovery," *J. Data Mining*, vol. 31, no. 3, pp. 377–382, 2002.
- [8] S. Marsland, *Machine Learning: An Algorithmic Perspective*, 2nd ed., Boca Raton, FL: CRC Press, 2014.
- [9] T. Chen and C. Guestrin, "XGBoost: A Scalable Tree Boosting System," in *Proc. 22nd ACM SIGKDD Int. Conf. Knowl. Discovery Data Mining (KDD)*, 2016, pp. 785–794.
- [10] J. H. Friedman, "Stochastic Gradient Boosting," *Computational Statistics & Data Analysis*, vol. 38, no. 4, pp. 367–378, Feb. 2002.
- [11] J. Dean and S. Ghemawat, "MapReduce: Simplified data processing on large clusters," in *OSDI '04: Proceedings of the 6th USENIX Symposium on Operating Systems Design and Implementation*, 2004, pp. 137–150.
- [12] P. I. Frazier, "A Tutorial on Bayesian Optimization," *arXiv preprint arXiv:1807.02811*, 2018.
- [13] E. Brochu, V. M. Cora, and N. de Freitas, "A tutorial on Bayesian optimization of expensive cost functions, with application to active user modeling and hierarchical reinforcement learning," *arXiv preprint arXiv:1012.2599*, 2010.
- [14] S. Bengio, "Model selection and model averaging: Cross-validation for time series," *Computational Statistics*, vol. 2, no. 3, pp. 128–135, 2003.
- [15] L. H. Yang and S. M. Ho, "Renewable energy strategies for sustainable development," *Energy Policy*, vol. 36, no. 8, pp. 2754–2758, 2008.
- [16] J. Schmidhuber, "Deep learning in neural networks: An overview," *Neural Networks*, vol. 61, pp. 85–117, Jan. 2015.